LESSON 01

课程导入

文献计量学、前沿趋势追踪与项目制学习框架

湖南大学 | 杨其晟 副教授

2026年春季学期

课程性质

项目制 · 可复现

00 课程构成

八大课程模块

文献检索与查新—知识图谱与计量方法—工具实操—案例分析—综述写作—多智能体趋势追踪—课程项目—学术报告

- 分组：建议3–5人/组。每组自选研究方向与开源项目（允许自带项目，但需满足可运行、可二开、可复现）。
- 主线任务：Fork/Clone开源项目→跑通→读懂关键模块→完成至少1个功能性改动（可验收）→输出可复现分析报告与mini review（6–8页）。
- 可复现要求：固定数据版本与检索式、固定软件依赖、提供一键运行命令（例如`python run_pipeline.py`或`make report`），输出目录结构清晰。
- 通用环境：Python 3.10+；建议使用Conda管理环境；Git用于版本管理；VSCode或PyCharm用于开发。
- 核心Python库建议：pandas、numpy、networkx、scikit-learn、matplotlib（可选：python-louvain、gensim、pyLDAvis、plotly）。
- 工具：CiteSpace（用于共被引与突现等）、VOSviewer（用于可视化共现/合作地图）。
- 引用管理：Zotero + BibTeX（或Word引用管理）。

00 课程构成

八大课程模块

文献检索与查新—知识图谱与计量方法—工具实操—案例分析—综述写作—多智能体趋势追踪—课程项目—学术报告

成绩构成

- 课堂考勤与参与：20%（出勤、课堂练习提交、讨论参与）。
- 综述实践（项目过程与论文）：60%（M1/M2/M3里程碑与过程作业）。
- 结果汇报：20%（期末学术报告与答辩）。
- 备注：旷课累计达到三次者，按规定本课程无成绩。

- M1（第4周末）：数据与检索方案（占20分/60分）
- M2（第10周末）：计量分析产出（占20分/60分）
- M3（第15周末）：终稿与可复现Release（占20分/60分）
- 过程加分/扣分：同伴评审质量、代码规范、复现性与诚信记录（±最多5分）

参考教材

李杰、陈超美，《CiteSpace：科技文本挖掘及可视化》

01 本节目标与当堂产出

教学目标

1. **理解课程定位**：学习目标、考核方式与学术诚信要求
2. **了解工作流**："项目制+开源二次开发"的产出规范（可复现）
3. **完成分组**：研究方向初选（2-3个备选方向）

当堂产出

分组完成

建议3-5人/组，确定组长

提交表格

《方向与开源项目候选表》

方向≥2；项目≥2

本节核心问题

怎样把"研究问题"变成可复现、可迭代的工程流程？

课程交流群

02 本节在项目流水线中的位置

上节
—

本节
课程导入

下节
检索式工程化

里程碑 M1 目标

数据
完成数据导入与清洗

检索
建立可复现检索式

筛选
完成文献筛选流程

第4周末前：数据/检索/筛选链条要跑通

本节产出复用：分组信息、研究方向、开源项目候选将在后续课程中持续迭代

03 关键概念A：课程核心概念

Bibliometrics

文献计量学：运用数学和统计学方法，对文献的外部特征进行定量分析

核心：发文量、被引频次、合作网络、共现分析

Frontier Tracking

前沿趋势追踪：识别近期快速增长/突现的主题或方法

核心：突现检测、时间切片、主题演化

Science Mapping

科学地图：用网络/聚类/可视化呈现知识结构与演化

核心：共被引网络、关键词共现、合作网络

Milestone Paper

里程碑论文：改变领域走向的关键论文

核心：高被引、关键桥接、突现、综述引用

易错点提醒

这些概念后面会变成图/表的**口径**，必须写进方法部分。不要混淆"Frontier"（前沿）与"Milestone"（里程碑）的时间维度。

04 关键概念B：仓库规范与项目制三要素

GitHub仓库结构规范

data/	src/	outputs/	reports/	paper/
原始数据	源代码	输出文件	报告文档	论文稿件

每次产出可追溯，版本化管理

可复现数据

- ✓ 数据来源标注清晰
- ✓ 导出时间戳记录
- ✓ 字段说明完整

可复现代码

- ✓ 依赖版本锁定
- ✓ 一键运行命令
- ✓ 随机种子固定

可解释结论

- ✓ 参数选择有理由
- ✓ 图表指向明确
- ✓ 局限充分讨论

05 小例子/反例：让概念落地

正确做法

问题定义

"我想了解近5年光电计算领域的研究热点和主要团队"

检索策略

时间窗：2020-2025；关键词：photonic computing, optical neural network；
数据源：Web of Science

分析方法

关键词共现网络 + 合作网络 + 突现检测

产出记录

reports/query_rationale.md
config/query.yaml
data/README.md

常见错误

错误1：口径不一致

检索时用"photonic computing"，分析时混入"optical computing"却不说明

错误2：参数不记录

阈值"随便试出来"，无法解释为什么选择Top 50而不是Top 30

错误3：数据源混乱

不同数据库混用却不说明偏差来源

课堂讨论

你们方向里最可能出现的**"口径不一致"**是什么？

06 方法/流程总览：可执行步骤

1 理解课程核心概念

Bibliometrics、Science mapping、Frontier/Trend tracking、Milestone paper

文献计量学 | 科学地图 | 前沿追踪 | 里程碑论文

2 建立项目制交付物

GitHub仓库结构、可复现命令、Release与版本管理

data/ | src/ | outputs/ | reports/ | paper/

3 明确学术诚信与责任

数据来源标注、引用规范、LLM使用边界（辅助不代写、可追溯）

数据来源 | 引用规范 | LLM边界

本节将生成的输出文件清单

- README.md → 项目说明
- 方向与开源项目候选表 → 研究方向
- requirements.txt → 依赖环境
- 环境截图 → 安装验证

07 关键步骤A：核心口径与做法

课程核心概念定义与边界

- **Bibliometrics**：定量分析方法，非质性评价
- **Science mapping**：可视化呈现，非因果推断
- **Frontier**：近期突现，区别于Milestone

学术诚信红线

- ✕ 数据来源必须标注
- ✕ 引用必须规范完整
- ✕ LLM辅助需披露使用方式

项目制交付物标准

1. 所有代码可一键运行
2. 所有图表可追溯到参数
3. 所有结论有证据支撑

仓库目录结构规范

```
project/
    ├── data/ # 原始数据
    ├── src/ # 源代码
    ├── outputs/ # 输出文件
    ├── reports/ # 报告文档
    └── paper/ # 论文稿件
```

核心原则

"参数不是细节"，它决定你看到的结构。要求学生把参数选择写成可辩护理由，而不是"随便试出来"。

08 关键步骤B：参数选择与解释

研究方向选择策略

策略1：兴趣驱动
选择你真正感兴趣的研究领域

策略2：问题导向
从具体研究问题出发反推方向

策略3：数据可得
确保相关文献数据可获取

开源项目评估维度

① 活跃度
最近更新时间、issue响应速度

② 文档完整度
README、API文档、示例代码

③ 可扩展性
模块化程度、插件机制

团队协作规范

- ✓ 明确分工与责任边界
- ✓ 定期同步进度与问题
- ✓ 代码review与互评

版本控制最佳实践

- ✓ 小步提交，频繁commit
- ✓ 写清晰的commit message
- ✓ 使用分支管理功能开发

09 Demo：项目仓库初始化

1 创建GitHub仓库

```
# 在GitHub网页上创建
Repository name: bibliometrics-project
Visibility: Public/Private
Initialize: Add README
```

2 建立目录结构

```
mkdir data src outputs reports paper
touch README.md .gitignore LICENSE
```

3 编写README骨架

```
# 项目名称
## 团队成员
## 研究方向
## 项目计划
```

4 添加.gitignore

```
# Python
__pycache__/
*.pyc
.env
# Data
data/raw/
```

5 选择LICENSE

推荐选择：

- MIT License（宽松）
- Apache 2.0（专利保护）
- GPL v3（开源传染）

10 课堂练习：最小可验收产出

任务1：完成分组

要求

- ✓ 建议3-5人/组
- ✓ 确定组长
- ✓ 明确分工

提交位置： README.md（成员列表）

任务2：提交候选表

《方向与开源项目候选表》

方向≥2： 列出2-3个备选研究方向

项目≥2： 列出2-3个候选开源项目

提交位置： docs/direction_candidates.md

助教巡检要点

文件位置
是否在对的位置?

可复现性
是否能一键跑通?

参数记录
是否写了参数?

练习阶段按rubric巡检，立即纠错最有效

11 快速分享与讲评

展示环节

2 组展示

- 每组1分钟
- 展示提交物路径
- 分享1条发现

随机点名/抽签

确保公平性，鼓励全员参与

讲评标准

可复现

代码、数据、参数是否完整

口径清晰

概念定义、边界是否明确

证据链可核对

结论是否有数据支撑

其他组任务

写下你学到的**"一个参数/一个坑"**

老师总结

本节最常见问题Top 3

建议：用"看仓库"来讲评，迫使学生把工程资产做好

12 QC Checklist：交付物质量自检

检索式"Query as Code"

落盘到 config/query.yaml

☐ 已落盘

变更日志

记录每次修改原因

☐ 已记录

括号优先级检查

NOT误杀检查

☐ 已抽样核对10条

导出字段齐全

作者/机构/关键词/摘要/参考文献/DOI

☐ 已确认

筛选表要求

含reason code，可追溯到原文献ID

现场任务

用QC清单对照检查你们仓库（打√/×）

QC不是挑刺，是帮助你们避免期末被问倒。建议把QC结果记录到reports/

LESSON 01 · SUMMARY

小结、作业与下节衔接

本节要点

- 课程核心概念
- 项目制交付物
- GitHub仓库结构
- 可复现命令
- Release与版本管理

课后作业

1. 建立GitHub仓库
2. 完成README骨架
3. 安装基础环境
4. 提交环境截图
5. 提交requirements.txt

下节预告

Lesson 02

检索式工程化

- 布尔表达式
- 字段限定
- 同义词扩展

作业截止时间：下次课前 | **助教答疑渠道：**GitHub Issues / 微信群

LESSON 02

检索式工程化

布尔表达式、字段限定与同义词扩展

湖南大学 | 杨其晟 副教授

01 本节目标与当堂产出

教学目标

1. **掌握布尔检索**：核心语法与常见陷阱（AND/OR/NOT、括号优先级）
2. **构建检索式**：能用"主题词-同义词-限定词-排除词"构建可复现检索式
3. **版本化管理**：将检索式写入可版本化配置（YAML/JSON）

当堂产出

v0检索式

含同义词表、限定条件、排除条件

配置文件

config/query.yaml（或同等配置文件）

本节核心问题

怎样把"研究问题"变成可复现、可迭代的检索式？

目标：提升precision/recall，并能解释为什么这样写

02 本节在项目流水线中的位置

上节
课程导入

→

本节
检索式工程化

→

下节
学术数据库

里程碑 M1 目标

数据
完成数据导入与清洗

检索
建立可复现检索式

筛选
完成文献筛选流程

第4周末前：数据/检索/筛选链条要跑通

本节产出复用：检索式将在后续数据导出、筛选流程中持续使用

03 关键概念A：检索式工程化要素

布尔逻辑

De Morgan 定律

NOT(A OR B) = NOT A AND NOT B

NOT(A AND B) = NOT A OR NOT B

常见误区

- OR范围过大
- NOT误杀
- 括号优先级混淆

字段限定

title	标题
abstract	摘要
keyword	关键词
author	作者
year	年份

Query as Code

将检索式参数化（时间窗、领域、文献类型）、记录版本与变更原因

04 关键概念B：检索式工程化要素

Query as Code

```
# 检索式参数化
time_window: 2020-2025
fields: [title, abstract]
doc_type: [article, review]

# 变更必写log
```

De Morgan 定律

```
NOT(A OR B)
= NOT A AND NOT B
```

```
NOT(A AND B)
= NOT A OR NOT B
```

布尔逻辑口诀

AND 收紧

同时满足多个条件

OR 扩展

满足任一条件即可

NOT 慎用

避免误杀相关文献

检索式模板

```
(Synonyms_O) AND
(Synonyms_M) AND
(Synonyms_C)
NOT (Exclusion)
```

05 小例子/反例：让概念落地

正确示例

```
# 光电生物传感器检索式
((sensor* OR biosensor*)
AND (FET OR "field effect transistor")
AND (tobacco OR nicotine))
```

结构解析

- **对象**：sensor/biosensor
- **方法**：FET/field effect transistor
- **场景**：tobacco/nicotine

常见错误

错误1：OR范围爆炸

```
# 错误写法
sensor* OR biosensor* AND FET
```

OR写到概念组外导致范围失控

错误2：NOT误杀

NOT tobacco可能误杀相关研究

正确做法

抽样核对10条命中结果，记录误差类型

产出记录

reports/query_rationale.md

白板练习

把研究问题拆成Object–Method–Context–Constraint四元组

06 方法/流程总览：可执行步骤

1 拆解研究问题

将研究问题拆成"对象-方法-场景-限定"四元组，并映射到检索字段

Object | Method | Context | Constraint

2 构建检索式

OR放同义词组内，AND连接概念组，NOT只用于明确排除并记录原因

```
(Synonyms_O) AND (Synonyms_M) AND (Synonyms_C) NOT (Exclusion)
```

3 版本化管理

每组在config/query.yaml写出v0检索式并现场互评（precision/recall）

query.yaml | 同义词表

本节将生成的输出文件清单

config/query.yaml 检索式配置	config/synonyms.yaml 同义词表	reports/query_rationale.md 设计理由

07 关键步骤A：核心口径与做法

括号优先级

优先级顺序

1. 括号 ()
2. NOT
3. AND
4. OR

```
# De Morgan 定律
NOT(A OR B) = NOT A AND NOT B
NOT(A AND B) = NOT A OR NOT B
```

字段限定

- **title**：precision高，recall低
- **abstract**：平衡precision/recall
- **keyword**：受控词表，bias小

同义词扩展

只在概念组内部OR

避免OR范围爆炸

维护同义词表

synonyms.yaml

变更记录

每次改动写变更原因

query_changelog.md

```
# 变更日志示例
v0.1: 初始检索式
v0.2: 增加同义词
```

核心原则

"参数不是细节"，它决定你看到的结构。要求学生把参数选择写成可辩护理由，而不是"随便试出来"。

08 关键步骤B：参数选择与解释

时间窗选择策略

策略1：研究周期匹配

根据领域发展周期选择（如近5年、近10年）

策略2：里程碑事件

以关键突破为起点（如某篇开创性论文发表年）

策略3：数据可得性

考虑数据库收录时间范围

文献类型限定

Article
原创研究论文

Review
综述文章

Conference
会议论文

语言与学科筛选

- ✓ 语言：English（默认）
- ✓ 学科：根据方向限定
- ✓ 记录筛选理由

检索式版本管理

- ✓ 语义化版本号（v0.1, v0.2...）
- ✓ 每次变更写原因
- ✓ 记录precision/recall变化

09 Demo：检索—导出—质量检查（1/3）

1 拆解研究问题

示例：光电计算领域研究热点

Object: photonic computing
Method: optical neural network
Context: AI acceleration
Constraint: 2020-2025

2 构建检索式

```
(("photonic computing" OR
"optical computing") AND
("neural network" OR "deep learning")
AND ("AI" OR "artificial intelligence"))
```

3 写入配置文件

```yaml
# config/query.yaml
query:
  object:
    - "photonic computing"
    - "optical computing"
  method:
    - "neural network"
  time_window: [2020, 2025]
```

4 现场互评

Precision: 命中文献的相关性

Recall: 相关文献的覆盖率

抽样检查10条结果

演示要点

演示要服务于当堂产出。确保学生能跟随操作，完成检索式配置。

10 Demo：检索—导出—质量检查（2/3）

导出样例数据

必须勾选的字段

- ☑ 作者
- ☑ 机构
- ☑ 参考文献列表
- ☑ 关键词
- ☑ 摘要
- ☑ DOI

```
# 运行数据质量检查
python data_quality.py
```

数据质量检查

缺失字段检测 关键
检查必填字段是否缺失

重复记录识别 关键
基于DOI/标题去重

格式一致性 建议
编码、分隔符检查

关键提醒

数据质量问题不解决，后面所有图都是**"垃圾进垃圾出"**

11 Demo：检索—导出—质量检查（3/3）

检索式优化

基于反馈调整
根据precision/recall优化

迭代策略
小步快跑，频繁验证

同义词维护

最佳实践
统一格式，定期更新

团队协作
共享维护，版本控制

变更日志

规范写法
时间+版本+原因+影响

可追溯性
便于复现与审查

完整工作流

问题拆解 → 构建检索式 → 导出数据 → 质量检查 → 迭代优化

12 课堂练习：最小可验收产出

任务1：提交v0检索式

内容要求

- ✓ 同义词表
- ✓ 限定条件
- ✓ 排除条件

提交位置： config/query.yaml

任务2：配置文件

config/query.yaml

```yaml
# 检索式配置
version: "0.1"
query:
  object: [...]
  method: [...]
  constraint: {...}
```

格式： YAML或JSON

助教巡检要点

文件位置
是否在对的位置?

可复现性
是否能一键跑通?

参数记录
是否写了参数?

练习阶段按rubric巡检，立即纠错最有效

13 快速分享与讲评

展示环节

2 组展示

- 每组1分钟
- 展示提交物路径
- 分享1条发现

随机点名/抽签

确保公平性，鼓励全员参与

讲评标准

可复现

代码、数据、参数是否完整

口径清晰

布尔逻辑、字段限定是否正确

证据链可核对

precision/recall是否有记录

其他组任务

写下你学到的**"一个参数/一个坑"**

老师总结

本节最常见问题Top 3

建议：用"看仓库"来讲评，迫使学生把工程资产做好

14 QC Checklist：交付物质量自检

检索式"Query as Code"

落盘到 config/query.yaml

☐ 已落盘

变更日志

记录每次修改原因

☐ 已记录

括号优先级检查

NOT误杀检查

☐ 已抽样核对10条

导出字段齐全

作者/机构/关键词/摘要/参考文献/DOI

☐ 已确认

筛选表要求

含reason code，可追溯到原文献ID

现场任务

用QC清单对照检查你们仓库（打√/×）

QC不是挑刺，是帮助你们避免期末被问倒。建议把QC结果记录到reports/

LESSON 02 · SUMMARY

小结、作业与下节衔接

本节要点

- 布尔逻辑（De Morgan定律）
- 字段限定
- Query as Code
- 同义词扩展策略

课后作业

1. 完善同义词词表（≥20术语）
2. 提交《检索式变更日志》
3. 记录两次优化改动

下节预告

Lesson 03

学术数据库与数据导出

- 字段、格式
- 数据质量

作业截止时间：下次课前 | **助教答疑渠道：**GitHub Issues / 微信群