LESSON 05

2026年春季学期

项目制 · 可复现

知识图谱与文献计量分析总体框架

从数据到科学地图

湖南大学

杨其晟 副教授

《文献计量学和前沿趋势追踪》

00 前序知识

- **库恩的科学发展模式理论**

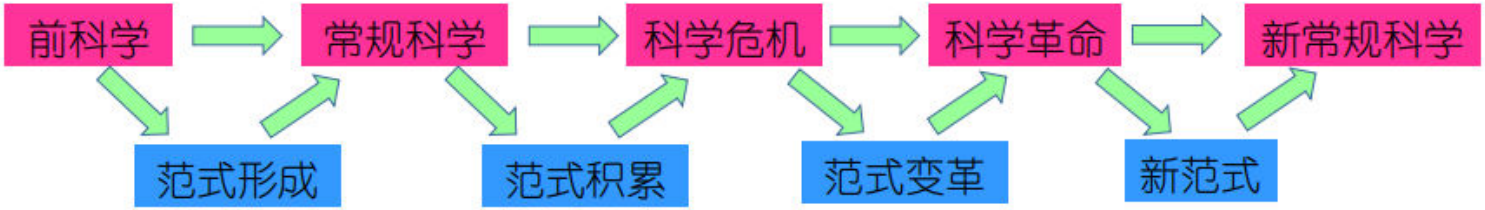

T.S.Kuhn (1962). 科学革命的结构

科学发展看成科学革命的历史过程:

① 前科学时期：科学在未形成统一范式之前处于前科学时期;
② 常规科学：范式形成之后,进入常规科学时期,人们在科学共同体中按范式解题,是范式积累期;
③ 科学危机：发展一定阶段,出现反常和危机;
④ 科学革命：人们寻求新的范式取代旧范式,导致科学革命的发生;
⑤ 新常规科学：迈进新范式下的新的常规科学期。

因此,科学发展本质上是常规科学与科学革命、积累范式与变革范式的交替运动过程。这个模式得到科学界的普遍认同。

01 本节目标与当堂产出

教学目标

1 理解知识图谱基本组成

掌握实体、关系、属性三大要素，理解图分析任务的基本原理

2 掌握文献计量分析流程

理解 data→preprocess→analysis→visualize→interpret 的完整工作流

3 认识经典科学规律

了解 Lotka/Bradford/Zipf 定律在计量中的作用与局限

当堂产出

图数据模型草图

《本项目图数据模型草图》

- 节点类型与属性定义
- 边类型与权重定义
- 示例数据说明

提交位置：docs/data_model.md

本节核心问题：如何从文献数据构建"科学地图"，回答领域结构与演化？

02 本节在项目流水线中的位置

上节

文献查新与研究空白

筛选流程、证据链与可辩护结论

→

本节

知识图谱与文献计量分析总体框架

从数据到科学地图

→

下节

文献计量指标体系

数量指标、影响力指标与归一化

里程碑 M1 目标

第4周末前：数据/检索/筛选链条要跑通

Week 3

当前进度

数据

完成数据导入与清洗

检索

建立可复现检索式

筛选

完成文献筛选流程

本节产出复用：图数据模型将在后续网络分析、指标计算、可视化中持续使用

03 关键概念A：定义/矩阵/指标/解释

知识图谱

V 节点（Vertex）

论文、作者、机构、关键词、期刊等实体

E 边（Edge）

引用、合作、共现、同属主题等关系

G = (V, E, A)
V=节点集, E=边集, A=属性集

文献计量工作流

1. 数据规范化
2. 网络构建
3. 指标计算
4. 聚类与时间演化
5. **结果解释**

经典科学规律

Lotka 定律

作者产出分布

少数作者发表大量论文，多数作者发表少量论文

Bradford 定律

核心期刊分布

少数期刊集中大量论文，形成核心-边缘结构

Zipf 定律

词频长尾分布

高频词少，低频词多，呈现幂律分布特征

⚠ **重要提醒：**这些规律用于理解分布现象，**不等于评价标准**

03 关键概念A：定义/矩阵/指标/解释

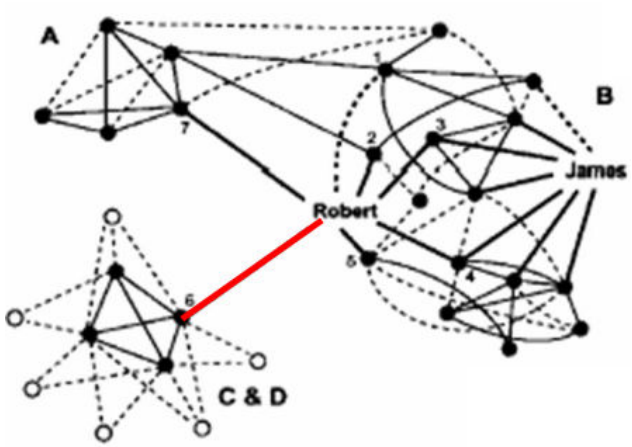

结构洞：“社会网络中的某个或某些个体和有些个体发生直接联系，但与其他个体不发生直接联系，无直接联系或关系间断(disconnection)的现象，从网络整体看好像网络结构中出现了洞穴”。

知识单元离散与重组理论：

- 科学范式的形成与变革=共引聚类的形成与演变=共性：知识单元的游离、重组与更新。
- 知识的重组不是简单的“物理反应”而是“化学反应”

我们的研究对象：

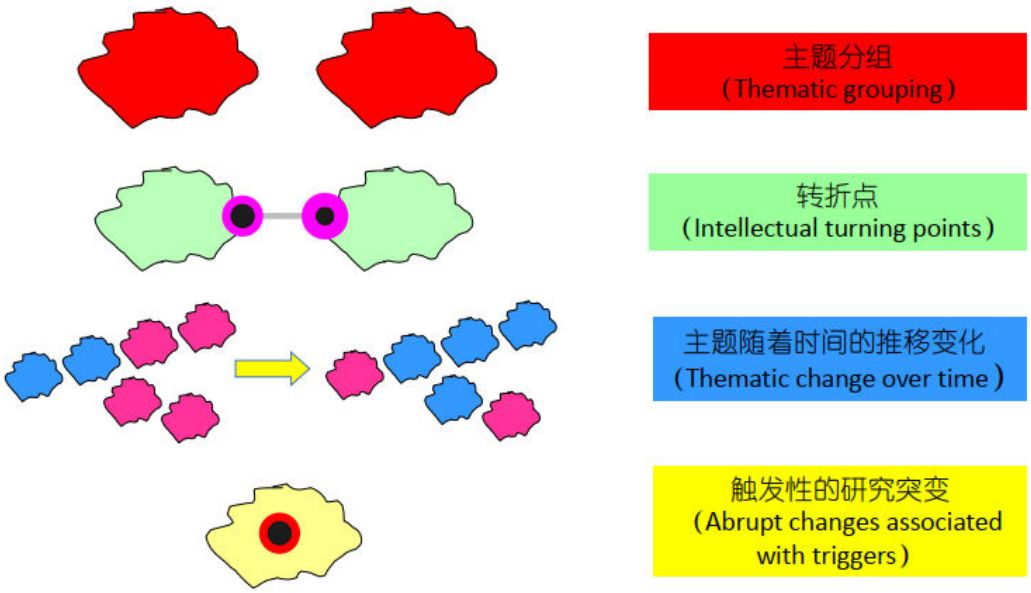

04 关键概念B：文献计量分析流程

完整分析流程

Data 原始数据 → Clean 数据清洗 → Build Graph 构建网络 → Metrics 指标计算 → Clustering 聚类分析 → Visualization 可视化 → Interpretation 结果解释

V 节点类型

- 论文
- 作者
- 机构
- 关键词
- 期刊

E 边类型

- 引用
- 合作
- 共现
- 耦合
- 共被引

核心原则：经典规律用于**理解分布**，不作为单一评价依据

05 小例子/反例：让概念落地

Toy矩阵示例

引用-被引二部矩阵 R

```
R = [1 0 1]
    [0 1 1]
    [1 1 0]
```

3篇文献 × 4条引用

共被引矩阵 $C = R^T R$

```
C = [2 1 1]
    [1 2 1]
    [1 1 2]
```

→ 文献1与文献2共被引1次

相似度计算

Cosine 相似度

cosine(a,b) = a·b / (||a|| ||b||)

适合高维稀疏数据

Jaccard 相似度

Jaccard = |A∩B| / |A∪B|

适合集合相似性

阈值选择

Top-N	Min Weight
保留前N条边	最小权重阈值

⚠ 影响网络密度与簇稳定性

结论表达顺序

结构 → 代表节点 → 时间演化

课堂练习

手算共被引边权重

产出记录

reports/query_rationale.md

05 小例子/反例：让概念落地

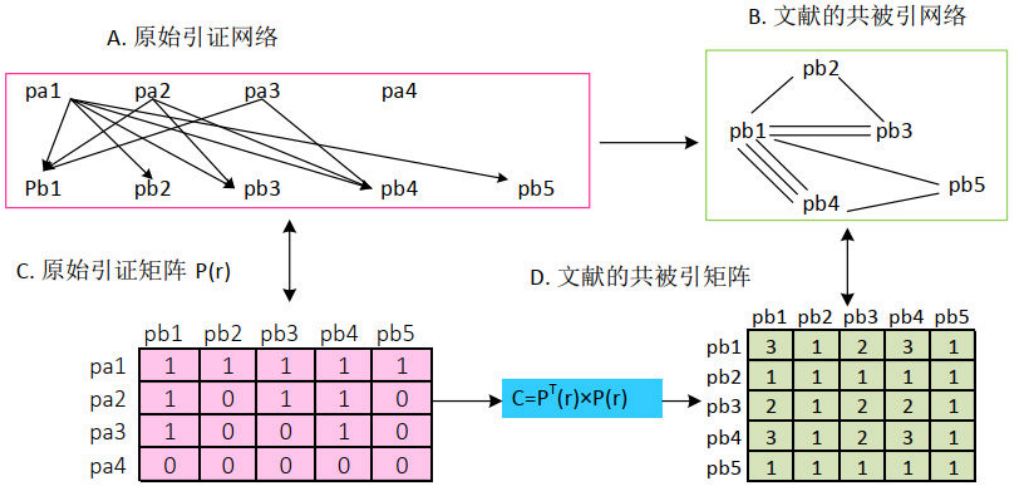

文献共被引分析

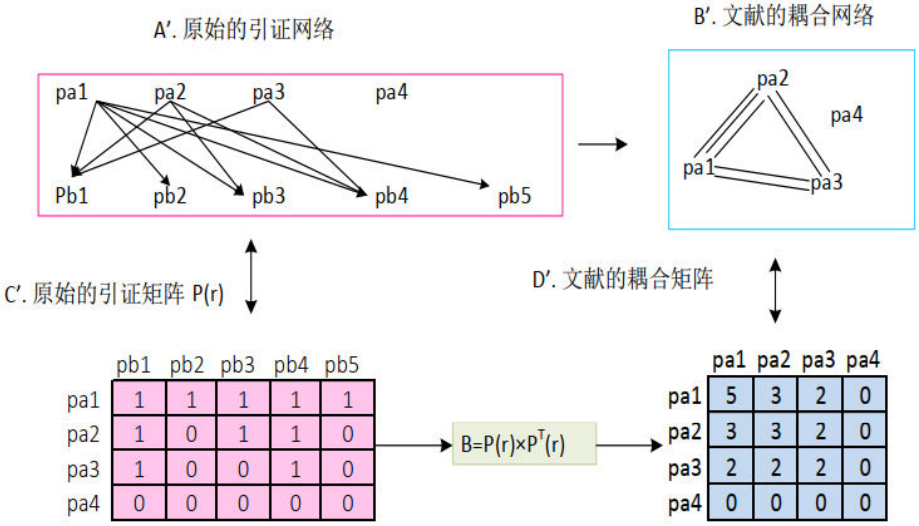

文献耦合分析

van Raan A F J. Advances in bibliometric analysis: Research performance assessment and science mapping[J]. Bibliometrics. Use and Abuse in the Review of Research Performance, 2014: 17-28.

06 方法/流程总览：可执行步骤

1 定义知识图谱要素

- 节点类型（论文/作者/机构/关键词/期刊）
- 边类型（引用/合作/共现/同属主题）
- 属性定义（标题/年份/被引次数等）

2 执行文献计量工作流

- 数据规范化与清洗
- 网络构建与指标计算
- 聚类分析与时间演化
- 结果解释与可视化

3 应用经典规律理解分布

- Lotka定律：作者产出分布
- Bradford定律：核心期刊
- Zipf定律：词频长尾现象

本节将生成的输出文件清单

docs/data_model.md
图数据模型文档

reports/data_quality.md
数据质量报告

强调'先流程后参数'：先知道每一步的输入/输出与风险点，再进入细节

07 关键步骤A：核心口径与做法

网络定义四要素

必须写入 params.md

1. **节点 = ?**
   论文/作者/机构/关键词
2. **边 = ?**
   引用/合作/共现/耦合
3. **权重 = ?**
   共被引频次/合作次数
4. **阈值 = ?**
   Top-N / Min Weight

相似度/中心性选择

选用理由
为什么选这个指标？适合什么场景？

解释口径
如何解读计算结果？什么值算高/低？

聚类质量评估

Modularity Q
社区结构强度
Q > 0.3 表示明显社区结构

Silhouette
簇内一致性
越接近1表示聚类效果越好

敏感性分析
至少做一次阈值对照，解释稳定/不稳定现象

核心原则："参数不是细节"，它决定你看到的结构。要求学生把参数选择写成可辩护理由，而不是"随便试出来"。

08 关键步骤B：参数选择与解释

参数记录规范

所有参数选择必须写入 params.md，包含选择理由

参数名称	参数值	选择理由
清晰的命名	具体数值	可辩护的解释

相似度度量

Cosine
适合高维稀疏数据，考虑向量方向

Jaccard
适合集合相似性，考虑共同元素

你的数据更适合哪个？

中心性指标

Degree
连接数，反映活跃度

Betweenness
桥接性，反映控制力

Eigenvector
影响力，反映重要性

阈值选择

Top-N
保留前N条最强边

Min Weight
保留权重大于阈值的边

⚠ 影响网络密度！

课堂提问：如果阈值改为两倍，你预计图会怎样变化？为什么？

09 Demo：图数据模型设计

设计步骤

1 确定节点类型

- 论文：标题、年份、被引次数
- 作者：姓名、机构、发文量
- 机构：名称、国家、论文数
- 关键词：词频、首次出现年份

2 确定边类型

- 引用关系：论文→论文
- 合作关系：作者↔作者
- 共现关系：关键词↔关键词

3 定义边权重

- 共被引频次：共同被引次数
- 合作次数：共同发表论文数

输出模板

docs/data_model.md

```
# 图数据模型

## 节点类型
  - 论文 (Paper)
  - 作者 (Author)
  - 机构 (Institution)
  - 关键词 (Keyword)

## 边类型
  - 引用 (Cites)
  - 合作 (Co-authors)
  - 共现 (Co-occurs)

## 示例数据
  | 节点ID | 类型 | 属性 |
  |--------|------|------|
```

演示要点
确保学生能跟随操作，完成图数据模型设计

演示要服务于当堂产出：确保学生能跟随操作，完成图数据模型设计

10 课堂练习：最小可验收产出

任务

每组提交《本项目图数据模型草图》

节点类型

- ✓ 节点类型定义
- ✓ 属性列表
- ✓ 示例数据

边类型

- ✓ 边类型定义
- ✓ 权重定义
- ✓ 方向性说明

示例数据

- ✓ 节点示例
- ✓ 边示例
- ✓ 属性值示例

提交位置

docs/data_model.md

格式：Markdown

助教巡检要点

1. 文件位置是否正确？
2. 节点/边定义是否清晰？
3. 属性是否完整？

练习阶段按rubric巡检：文件是否在对的位置？是否能一键跑通？是否写了参数？立即纠错最有效

11 快速分享与讲评

展示环节

2组展示（每组1分钟）

1. 展示提交物路径
2. 分享1条发现

随机点名/抽签，确保公平性

讲评标准

可复现

代码、数据、参数是否完整？

口径清晰

概念定义、边界是否明确？

证据链可核对

结论是否有数据支撑？

其他组任务

写下你学到的

"一个参数/一个坑"

老师总结

本节最常见问题 Top 3

1. 节点类型定义不完整
2. 边权重说明不清晰
3. 缺少示例数据

建议：用"看仓库"来讲评，迫使学生把工程资产做好

12 QC Checklist：交付物质量自检

1 网络定义写清

节点/边/权重/阈值

→ 写入 params.md

2 清洗/消歧规则

版本化管理

→ cleaning_rules.md

3 阈值敏感性对照

至少做一次对照实验

密度/连通分量/簇稳定性

4 结论指向明确

必须指向图/表/Top列表

建立完整证据链

现场任务

用QC清单对照检查你们仓库

✓ ✗

QC不是挑刺：是帮助你们避免期末被问倒。建议把QC结果记录到reports/

SUM Lesson 5 小结、作业与下节衔接

本节要点

知识图谱
节点、边、属性三大要素

分析流程
数据→清洗→网络→指标→聚类→可视化→解释

经典规律
Lotka/Bradford/Zipf定律

课后作业

1. **数据整理**
   将数据整理为统一表结构（pandas DataFrame schema）
2. **质量报告**
   输出字段缺失率报告
3. **文献阅读**
   总结Lotka/Bradford/Zipf任一规律及其局限（200字）

下节预告

LESSON 06

文献计量指标体系

- 数量指标
- 影响力指标
- 归一化方法

作业截止时间：下次课前

助教答疑渠道：GitHub Issues / 微信群

LESSON 06

2026年春季学期
项目制 · 可复现

文献计量指标体系

数量指标、影响力指标与归一化

湖南大学
杨其晟 副教授

《文献计量学和前沿趋势追踪》

01 本节目标与当堂产出

教学目标

1 掌握常用指标

理解定义、计算方法与适用场景

2 理解比较偏差

认识领域差异与时间差异带来的偏差，学会基本归一化思路

3 确定指标清单

为后续报告确定指标清单与口径（可解释、可复现）

当堂产出

指标规范文档

reports/metrics_spec.md

- 指标定义与公式
- 口径说明
- 局限与注意事项

提交位置：reports/metrics_spec.md

本节核心问题：如何从文献数据构建"科学地图"，回答领域结构与演化？

02 本节在项目流水线中的位置

上节

知识图谱与文献计量分析

总体框架
从数据到科学地图

→

本节

文献计量指标体系

数量指标、影响力指标
与归一化

→

下节

共被引分析

定义、矩阵构建
相似度与聚类解释

里程碑 M1 目标

第4周末前：数据/检索/筛选链条要跑通

Week 3

Session 2

数据

完成数据导入与清洗

检索

建立可复现检索式

筛选

完成文献筛选流程

本节产出复用：指标规范将在后续网络分析、结果解释、论文写作中持续使用

03 关键概念A：数量指标与影响力指标

数量类指标

反映研究活跃度

发文量

一定时间内的论文发表数量

增长率

发文量的年度变化率

合作比例

合作论文占总论文的比例

影响力类指标

反映学术影响力

总被引

论文被引用的总次数

篇均被引

平均每篇论文的被引次数

h-index

有h篇论文各被引至少h次

g-index

g篇论文共被引至少g^2次

归一化必要性

按年份分层

不同年份的论文被引时间不同

按学科分层

不同学科引用习惯差异大

分位数/标准化

避免跨领域直接比较

04 关键概念B：指标计算与归一化

评价与分析区别

本课程指标用于"结构与趋势"分析，不作为单一科研评价依据

✓ 分析用途

识别研究热点、追踪趋势、理解领域结构

✗ 评价局限

单一指标不能全面评价学术贡献

归一化方法

按学科/年份/类型

分层比较

分位数

百分位排名

z-score

标准化分数

避免跨领域直接比数值

h-index

定义

最大h使得至少h篇论文各被引≥h次

适用场景

作者/机构影响力评估

平衡数量与质量

时间窗影响

总被引/篇均被引

受时间窗影响显著

正确做法

按年份分层比较

注意时间偏差

05 小例子/反例：让概念落地

h-index计算示例

某作者的论文被引次数（降序排列）

[10, 8, 7, 5, 4, 3, 2, 1, 1, 0]

计算过程

第1篇：被引10次 ≥ 1 ✓
第2篇：被引8次 ≥ 2 ✓
第3篇：被引7次 ≥ 3 ✓
第4篇：被引5次 ≥ 4 ✓
第5篇：被引4次 ≥ 5 ✗

h-index = 4

指标误用案例

✕ **错误1：跨学科比较发文量**
不同学科发文习惯差异巨大，直接比较无意义

✕ **错误2：忽略时间因素**
2020年论文与2010年论文的被引时间不同

✕ **错误3：单一指标评价**
仅用h-index评价学者不全面

课堂练习

手算h-index（给定一组论文的被引次数）

正确做法
多指标综合分析

关键原则
指标用于分析，非评价

产出记录
reports/metrics_spec.md

06 方法/流程总览：可执行步骤

1 数量类指标

- 发文量
- 增长率
- 合作比例

2 影响力指标

- 总被引
- 篇均被引
- h-index
- g-index

3 期刊/会议指标

- IF（影响因子）
- CiteScore
- SJR

了解来源与局限

4 归一化方法

- 按年份分层
- 按学科分层
- 分位数
- 标准化

本节将生成的输出文件清单

reports/metrics_spec.md
指标规范文档

outputs/metrics.csv
指标计算结果

outputs/figures/
指标可视化图表

强调'先流程后参数'：先知道每一步的输入/输出与风险点，再进入细节

07 关键步骤A：核心口径与做法

指标选择原则

1 根据研究问题选择
不同问题需要不同指标

2 避免指标滥用
不盲目追求高指标

3 多指标综合分析
单一指标不全面

网络定义四要素

必须写入 params.md

节点 = ?	边 = ?
权重 = ?	阈值 = ?

相似度/中心性

- 选用理由
- 解释口径

聚类质量

Modularity Q	Silhouette

核心原则："参数不是细节"，它决定你看到的结构。要求学生把参数选择写成可辩护理由，而不是"随便试出来"。

08 关键步骤B：参数选择与解释

参数记录规范

所有参数选择必须写入 params.md，包含选择理由

参数名称	参数值	选择理由
清晰的命名	具体数值	可辩护的解释

时间窗选择

影响

影响指标计算结果

要求

需明确说明

⚠ 关键参数！

自引处理

选择

去自引 vs 不去自引

影响

对结果有显著影响

需记录口径

领域归一化

差异

不同学科引用习惯不同

要求

跨领域比较必须归一化

避免直接比较

课堂提问：如果阈值改为两倍，你预计图会怎样变化？为什么？

09 Demo：指标计算与对比（1/3）

常用指标计算

发文量统计

按年份/作者/机构统计

被引次数统计

总被引/篇均被引

h-index计算

手动+代码实现

Python代码示例

```
# 计算h-index
def h_index(citations):
    citations.sort(reverse=True)
    h = 0
    for i, c in enumerate(citations):
        if c >= i + 1:
            h = i + 1
    return h
```

输出格式：CSV表格+可视化图表

对比两种口径

去自引 vs 不去自引

- → 观察指标变化
- → 分析影响程度

不同时间窗

- → 近5年 vs 近10年
- → 观察趋势变化

演示要服务于当堂产出：确保学生能跟随操作，完成指标计算与对比

10 Demo：指标计算与对比（2/3）

归一化方法演示

对比归一化前后的结果差异

按年份分层

比较同一年份发表的论文

消除时间偏差

按学科分层

使用学科基准值

消除领域偏差

z-score标准化

均值为0，标准差为1

$z = (x-\mu)/\sigma$

对比归一化前后的结果差异

归一化前

计算机科学	平均被引: 45
数学	平均被引: 15
生物学	平均被引: 80

✕ 无法直接比较

归一化后（z-score）

计算机科学	z = 0.5
数学	z = 0.3
生物学	z = 0.7

✓ 可跨领域比较

关键结论：归一化对跨领域比较至关重要，消除学科间引用习惯差异

11 Demo：指标计算与对比（3/3）

指标规范文档模板

```
# reports/metrics_spec.md

## 指标名称
  h-index

## 计算公式
  max{h: 至少有h篇论文
  各被引≥h次}

## 适用场景
  - 作者影响力评估
  - 机构影响力评估

## 口径说明
  - 时间窗：2010-2025
  - 去自引：是

## 局限
  - 忽略高被引论文差异
  - 受时间窗影响大
```

文档内容要求

1. 指标名称
2. 计算公式（LaTeX）
3. 适用场景
4. 口径说明
5. 局限与注意事项

演示要点

确保学生能跟随操作，完成指标规范文档

关键：每个指标都要有明确的口径和局限说明

演示要服务于当堂产出：确保学生能跟随操作，完成指标规范文档

12 课堂练习：最小可验收产出

任务

每组提交 reports/metrics_spec.md（指标定义、公式、口径、局限）

数量指标

- ✓ 至少2个
- ✓ 含计算公式

影响力指标

- ✓ 至少2个
- ✓ 含计算公式

归一化方法

- ✓ 至少1个
- ✓ 含适用场景

提交位置

reports/metrics_spec.md

格式：Markdown

助教巡检要点

1. 文件位置是否正确？
2. 指标定义是否清晰？
3. 公式是否正确？
4. 局限是否说明？

练习阶段按rubric巡检：文件是否在对的位置？是否能一键跑通？是否写了参数？立即纠错最有效

13 快速分享与讲评

展示环节

2组展示（每组1分钟）

1. 展示提交物路径
2. 分享1条发现

随机点名/抽签，确保公平性

讲评标准

可复现

代码、数据、参数是否完整？

口径清晰

指标定义、公式是否正确？

证据链可核对

局限是否充分说明？

其他组任务

写下你学到的

"一个参数/一个坑"

老师总结

本节最常见问题 Top 3

1. 指标公式不完整
2. 口径说明不清晰
3. 局限分析不充分

建议：用"看仓库"来讲评，迫使学生把工程资产做好

14 QC Checklist：交付物质量自检

1 网络定义写清

节点/边/权重/阈值

→ 写入 params.md

2 清洗/消歧规则

版本化管理

→ cleaning_rules.md

3 阈值敏感性对照

至少做一次对照实验

密度/连通分量/簇稳定性

4 结论指向明确

必须指向图/表/Top列表

建立完整证据链

现场任务

用QC清单对照检查你们仓库

✓ ✗

QC不是挑刺：是帮助你们避免期末被问倒。建议把QC结果记录到reports/

SUM Lesson 6 小结、作业与下节衔接

本节要点

数量指标
发文量、增长率、合作比例

影响力指标
总被引、篇均被引、h-index、g-index

期刊指标
IF、CiteScore、SJR

归一化
按年份/学科分层、分位数、z-score

课后作业

1. **指标计算函数**
   在代码中实现至少2个指标计算函数（带docstring与示例）

2. **口径对比**
   对比两种口径（例如是否去自引）对结果的影响（写200字）

下节预告

LESSON 07

共被引分析

- 定义与矩阵构建
- 相似度计算
- 聚类解释

作业截止时间：下次课前

助教答疑渠道：GitHub Issues / 微信群